

是的！有不少后续工作正在研究提升大模型在“不知道/无法判断”这类情况的能力，尤其是在事实核查、因果推理、不确定性识别（uncertainty）和自我评估（self-awareness）方面。下面我按主题给你梳理几类重要趋势和方向：

✅ 1) 不确定性量化 & 识别未知答案

目标：让模型更好地区分“知道”和“不知道”。

📌 Token-Level 不确定性量化

研究者提出基于令牌级别不确定性得分去检测 LLM 生成的“可疑/不可靠”部分，从而识别模型输出中的错误或“未知”信息，而不是单纯依赖置信度分数。（[arXiv](#)）

📌 模型内部状态作为信号

一些研究尝试利用模型的隐藏层激活等内部表征来预测答案的真实性或是否应拒答。这种方法比表面置信度更具判别能力。（[Reddit](#)）

📌 构造专门数据集评估未知能力

比如 Honesty 这类数据集（包含已知 vs 未知问题）用于评估模型是否能准确拒绝未知答案，而不是盲目给出“看起来合理”的回答。（[MDPI](#)）

✅ 2) 校准（Calibration）与自信度调整

大模型常常在输出错误时表现得过于自信，这使得 NEI/“不知道”判断更难。为了改进这点，有一些方向：

✓ **置信度校准研究**：研究显示 LLM 输出的置信度往往和真实准确率不匹配（存在 calibration gap）。为此有文献提出校准策略提升置信度的可靠性。（[Nature](#)）

✓ **训练/微调阶段的校准方法**：像 Temperature Scaling、PPO/DPO 阶段校准等方法被应用于 LLM，让其在不确定时给出更合理的概率输出。（[PMC](#)）

✅ 3) 让模型显式表达不确定或拒答

✓ Prompt + 不确定性提示

有实验显示，在回复中加入明确的不确定性描述（比如“我不是很确定这个答案是 A”，或置信区间）可以帮助用户更好识别答案的可靠性。（[UC Irvine News](#)）

✓ 诚实 (Honesty) 和自省 (Metacognition) 训练

研究认为可以训练模型不只输出答案，还输出它对自己答案的置信度或拒答概率，甚至在无法回答时拒绝输出。这种元认知训练是提升“不知道能力”的一个重要方向。（[MDPI](#)）

✅ 4) 因果与结构化推理辅助减少错误

特别是像 CHECKWHY 这种含有因果结构的数据集，推动了下列方向：

因果结构学习

不仅让模型做判断，还训练它构建因果图/DAG，帮助模型从结构角度更稳健地推理，而不是靠统计联想。例如有 work 用 DAG 构建方法来增强 LLM 的因果推理能力。([龙腾亚太](#))

推理可信度量

一些最新研究在评估因果任务时，结合了 uncertainty metrics (entropy, calibration, consistency 等) 来衡量模型在推理时的信心水平，为“不知道”评估提供指标。([ACL Anthology](#))

5) 集成外部知识 & RAG 风格系统

单靠模型自身并不能永远回答未知情况，所以常见的思路是：

结合检索增强生成 (RAG)

将外部证据库检索结合到 LLM 生成过程中，当 external retrieval 结果不足时，让系统退回“无法判断”而不是凭空生成答案。([Computerworld](#))

多模块事实核查系统

一些实证系统先做检索 → 决策 → 解释，这种体系比无工具的单一 LLM 更能识别 NEI 结果并拒答。([科学直通车](#))

未来的研究方向 / 改进空间

虽然有上面的进展，但研究仍远未成熟：

更强的元认知与拒答机制

让 LLM 能真正判断边界何时不能回答，而不是自信地胡编。

更好的 uncertainty 评估指标

例如结合内部概率分布、逻辑一致性等度量，更全面判断“不知道”。

结构化逻辑与因果推理结合

把语义 + 结构化知识推理结合，而不是仅靠语言模式。

人机协作辅助决策

模型标注不确定区域/原因，提升用户对结果可信度的判断。

综合总结

方向	改进点	是否已有进展
不确定性识别	模型内部衡量不确定	✅ 有研究
置信度校准	让输出概率更靠谱	✅ 有进展
拒答机制	模型拒绝回答未知	初步研究
RAG / 外检融合	借外部证据判断 NEI	有实证方案
因果 + 推理结构	结合逻辑与结构	新兴方向

📌 核心结论

目前的工作正在逐步让大模型：

- ✅ 更“知道自己不知道”
- ✅ 更合理地表达不确定性
- ✅ 能通过结构化推理与外检辅助提高可靠性

但要真正让模型像人类专家那样稳健拒答、并提供清晰不确定性解释，还有大量研究空间和技术挑战。
(link.springer.com)

当然可以！下面我给你整理一份最新、与“提升大模型正确拒答/不确定性能力”相关的论文和资源清单，这些工作都在探讨 LLM 在“不知道”/拒答/不确定性判断上的能力提升、评估指标、及训练方法——非常适合用于阅读和研究。

📖 1. “Can LLMs Refuse Questions They Do Not Know? — Knowledge-Aware Refusal”

- 📄 标题: *Can LLMs Refuse Questions They Do Not Know? Measuring Knowledge-Aware Refusal in Factual Tasks* (ICLR 2026)
- 📖 核心内容: 提出了 **Refusal Index (RI)**，作为衡量 LLM 是否能在自己不知道的问题上准确拒绝 (refuse) 的一种稳健指标，而不是简单统计拒绝率。该指标能更客观评估模型在“不知道”时拒答的能力。([arXiv](https://arxiv.org))
- 🔗 主题: 拒答能力评估、知识不确定性、真实拒答行为衡量。

📖 2. US-Tuning: 教模型更好地说 “I don’t know”

- 📄 标题: *Know the Unknown: An Uncertainty-Sensitive Method for LLM Instruction Tuning* (ACL 2025)
- 📖 核心内容: 提出了一种指令微调方法 **US-Tuning**，增强 LLM 对自身知识边界的敏感性和拒答能力，使模型在缺乏知识时更可能说“不知道”而不是胡乱回答。([ACL Anthology](https://aclanthology.org))
- 🔗 主题: 提升“不知道”回答能力、减少幻觉、改进 QA 上的拒答行为。

3. AbstentionBench: LLM 无法回答时应拒答但现在做得不好

 标题: *AbstentionBench: Reasoning LLMs Fail on Unanswerable Questions* (arXiv 2025)

 核心内容: 构建了覆盖 20 类数据集的基准集合 **AbstentionBench**, 用于评估 LLM 在“无法回答 / 无定义问题”时的拒答能力。实验表明, 大模型在这种任务上表现极差, 并且 scale (增大模型) 并不能改善这个问题。([arXiv](#))

 主题: 实际拒答评测、基准数据集、评估 LLM 自制拒答行为。

4. UA-Bench: 区分数据不确定性 vs 模型不确定性

 标题: *Beyond “I Don’t Know”: Evaluating LLM Self-Awareness in Discriminating Data and Model Uncertainty* (2026)

 核心内容: 提出了新的 benchmark **UA-Bench**, 区分数据不确定性 (输入本身模糊) 与模型不确定性 (模型能力外)。实验显示当前 LLM 即使准确率高也没有区分这两类不确定性的能力。([arXiv](#))

 主题: 自身不确定性评估、更细粒度的拒答逻辑。

5. 全面综述: LLM 不确定性估计的理论与实践

 标题: *A Survey of Uncertainty Estimation in LLMs: Theory Meets Practice*

 核心内容: 系统综述 LLM 不确定性的来源、估计方法 (如贝叶斯方法、熵、集成策略) 以及衡量 metric, 包括在 out-of-distribution / question clarification 等应用中的不确定性评估方法。([arXiv](#))

 主题: LLM 不确定性概念、方法与挑战。

6. 不确定性与生成解释: 增强模型推理可信度

 标题: *Rethinking LLM Uncertainty: A Multi-Agent Approach to Estimating Black-Box Model Uncertainty* (EMNLP 2025)

 核心内容: 针对黑箱 LLM 的不确定性估计提出了 **DiverseAgentEntropy** 方法, 通过多个代理交互评估其对同一问题不同变体回答的一致性来衡量不确定度。([ACL Anthology](#))

 主题: 多代理推理、回答一致性检测、用 entropy 估计不确定性。

7. 更宽泛的不确定性与可信度方向综述

 文章标题: *Survey of Uncertainty Estimation in LLMs — Sources, Methods, Applications, Challenges*

 核心内容: 对 LLM 不确定性估计进行了全面综述, 区分数据 / 模型不确定性, 讨论衡量指标和评估挑战, 是理解“为什么模型会自信地给出错误答案以及怎样评估不确定性”的好资源。([科学直通车](#))

 主题: 原则性不确定性分析、UQ 方法全景。

推荐阅读顺序和用途

论文/资源	适用场景	阅读顺序建议
Refusal Index (ICLR 2026)	想度量模型是否能拒答	☆☆☆
US-Tuning (ACL 2025)	想提升“不知道”行为	☆☆
AbstentionBench	想评估实际拒答性能	☆☆
UA-Bench (2026)	想区分不同类型不确定性	☆☆☆☆
Uncertainty Summaries	想全面理解不确定性	☆
Multi-Agent & Entropy Approaches	对 uncertainty 技术细分感兴趣	☆

这些研究能帮助解决的主要问题

- ✅ 衡量模型“不确定”行为的指标（Refusal Index）
- ✅ 增强模型在知识不足时拒答的能力（US-Tuning）
- ✅ 系统评估模型拒答能力的基准（AbstentionBench / UA-Bench）
- ✅ 理论上理解 LLM 不确定性的来源和处理方法（Uncertainty Surveys）
- ✅ 基于生成一致性估计不确定性的方法（Multi-Agent）

如果你需要，我还可以：

◆ 按主题（比如“NEI 提升 + 训练方法”、“LLM 拒答评估 Bench 解读”、“不确定性 metrics 对比”）给出 更详细的笔记 + 阅读路线图。

需要吗？